ANNO ACCADEMICO 2024/2025

Agenti Intelligenti

Teoria

Altair's Notes

DIPARTIMENTO DI INFORMATICA

Premessa

Licenza

Formato utilizzato

Box di "Concetto sbagliato":

Concetto sbagliato 0.1: Testo del concetto sbagliato

Testo contente il concetto giusto.

Box di "Corollario":

Corollario 0.0.1 Nome del corollario

Testo del corollario. Per corollario si intende una definizione minore, legata a un'altra definizione.

Box di "Definizione":

Definizione 0.0.1: Nome delle definizione

Testo della definizione.

Box di "Domanda":

Domanda 0.1

Testo della domanda. Le domande sono spesso utilizzate per far riflettere sulle definizioni o sui concetti.

Box di "Esempio":

Esempio 0.0.1 (Nome dell'esempio)

Testo dell'esempio. Gli esempi sono tratti dalle slides del corso.

Box di "Note":

Note:-

Testo della nota. Le note sono spesso utilizzate per chiarire concetti o per dare informazioni aggiuntive.

Box di "Osservazioni":

Osservazioni 0.0.1

Testo delle osservazioni. Le osservazioni sono spesso utilizzate per chiarire concetti o per dare informazioni aggiuntive. A differenza delle note le osservazioni sono più specifiche.

1 Introduzione

1.1 Perché Agenti Intelligenti?

La storia della computazione è stata definità da 5 trends:

- *Ubiquità*.
- *Interconnessione*.
- *Intelligenza*.
- *Delega*.
- *Human-orientation*.

Ubiquità:

- La continua riduzione dei costi di elaborazione ha permesso di introdurre capacità di elaborazione in luoghi e dispositivi che una volta sarebbero stati antieconomici.
- Ma mano che la capacità di elaborazione si diffonde, elementi sofisticati e intelligenti diventano onnipresenti.

Interconnessione:

- I sistemi informatici, attualmente, non esistono più da soli, ma sono collegati in rete in grandi sistemi distribuiti.
- Per esempio internet.
- Alcuni ricercatori stanno proponendo modelli teorici che ritraggono l'informatica principalmente come un processo di interazione.

Intelligenza e Delega:

- La complessità dei compiti che siamo capaci di automatizzare e delegare ai computer è cresciuta costantemente.
- Viene dato più controllo ai computer:
  - *Fly-by wire aircraft.*
  - *Fly-by-wire cars.*

Human-orientation:

- CI si sposta da una vista orientata alla macchina e alla programmazione verso una visione a metafore e concetti più vicine alla comprensione umana.
- I programmatori concettualizzano e realizzano software in termini di livello superiore, più orientato all'uomo, *astrazioni*.

Note:-

Delega e intelligenza implicano la necessità di costruire sistemi informatici in grado di agire efficacemente.

Questo implica:

- La capacità di agire dei sistemi informatici *in modo indipendente*[1].
- La capacità dei sistemi informatici di agire in un modo che *rappresentino nel migliore dei modi i nostri interessi* durante l'interazione con altri esseri umani o sistemi.
- Interconnessione e distribuzione portano a sistemi che possono *cooperare* e *raggiungere accordi*, *agreements* o *competere* con altri sistemi che hanno interessi diversi.
- Tutto ciò porta alla nascita di un nuovo campo dell'informatica: *sistemi multiagente*.

1.1.1 Agenti e Sistemi Multiagente

Definizione 1.1.1: Agente

Un agente è un sistema di compilazione, un sistema informatico, capace di agire in modo indipendente per conto di un utente o proprietario (capendo cosa deve essere fatto per soddisfare gli obiettivi di progettazione, piuttosto che essere costantemente informato).

Definizione 1.1.2: Sistema Multiagente

Un sistema multiagente (MAS) consiste in una serie di agenti, che interagiscono l'uno con l'altro. Nel caso più generale, gli agenti agiscono per conto di utenti con differenti obiettivi e mtivazioni.

Note:-

per interagire con successo, richiedono la capacità di *cooperare*, *coordinarsi* e *negoziare* tra loro.

Un sistema multiagente risponde a queste domande:

- Come può emergere la cooperazione in società composte da agenti *self-interested*?
- Quali tipi di linguaggi possono essere utilizzati dagli agenti per comunicare?
- Come possono gli agenti *self-interested* riconoscere conflitti? E come possono raggiungere accordi?
- Come possono gli agenti autonomi coordinare le proprie attività in modo da raggiungere cooperativamente gli obiettivi?

Ma soprattutto:

- Come possiamo creare agenti capaci di agire in modo indipendente, autonomo, in modo che possano svolgere con successo i compiti che gli deleghiamo?
- Come possiamo creare agenti capaci di interagire con altri agenti con il fine di portare a termine con successo i compiti delegati, soprattutto quando non si può presumere che gli altri agenti condividano gli stessi interessi e obiettivi?

[1] Un oggetto fa qualcosa perché la deve fare, un agente fa qualcosa perché la vuole fare. Hey non avevo idea di essere diventat un oggetto quando mi sono iscritt all'università.

Osservazioni 1.1.1

- Il primo caso è un problema di progettazione/design di un agente.
- Il secondo caso è un problema di progettazione/design di società di agenti.

1.1.2 Approccio Interdisciplinare

Il campo dei sistemi multiagente è influenzato e ispirato da molti altri campi:

- Economia.
- Filosofia.
- Teoria dei giochi.
- Logica.
- Ecologia.
- Scienze sociali.

Note:-

Questo è sia un punto di forza (perché ci sono molte idee diverse) sia un punto di debolezza (perché ci sono molte idee diverse lol).

Domanda 1.1

Non è solo AI?

- Non abbiamo bisogno di risolvere tutti i problemi di intelligenza artificiale per costruire agenti utili.
- L'AI classica ignorava gli aspetti sociali dell'agire.

Domanda 1.2

Non è solo economia/teoria dei giochi?

- Nella misura in cui la teoria dei giochi fornisce descrizione di concetti, non sempre ci dice come calcolare soluzioni.
- Alcune assunzioni in economia/teoria dei giochi potrebbero non essere valide o utili nella costruzione di agenti artificiali.

Domanda 1.3

Non sono solo scienze sociali?

- Possiamo trarre spunti dallo studio di società umane, ma non ci sono particolari motivi per credere che le società artificiali siano costruite allo stesso modo[2].
- Si trae ispirazione, ma non si assume a prescindere.

[2]Effettivamente sarebbe raccapricciante se gli agenti cominciassero a uccidersi a vicenda per questioni triviali.

1.2 Cosa si Intende per Agenti Intelligenti?

Ricordiamo che un agente è un sistema di computazione capace di agire *autonomamente* in un qualche *ambiente* con il fine di raggiungere gli *obiettivi* per cui è progettato.

Note:-

La caratteristica principale degli agenti e la loro autonomia.

Figure 1.1: Agente che interagisce con l'ambiente.

Note:-

In figura 1.1 il fatto che l'agente e l'ambiente sono disegnati con due rettangoli identici non è casuale: sono due elementi alla pari.

Esempio 1.2.1 (Agenti)

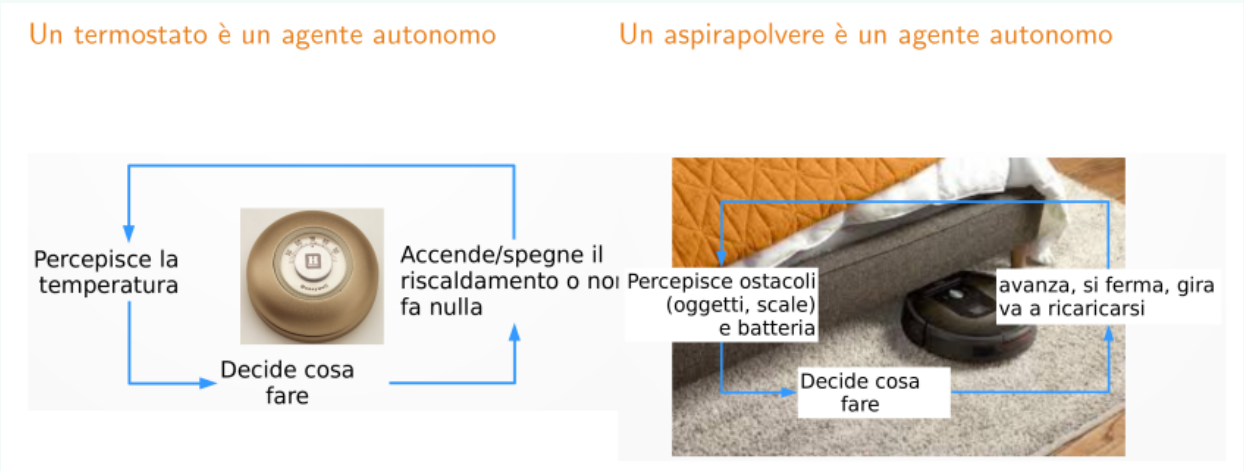

Autonomia e controllabilità:

- Al di fuori della comunità AI, gli agenti autonomi intelligenti sono percepiti come entità consapevoli di sé, incontrollabili, la cui autonomia emerge come proprietà "extra-programma".
- Un agente può prendere iniziative che non sono incluse fin dall'inizio nel suo programma.

1.2.1 Test di Turing

Il test di Turing:

- Una persona o un computer sono nascosti a un investigatore (fig. 1.2).

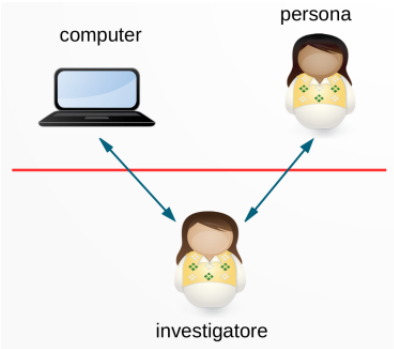

Figure 1.2: Rappresentazione del test di Turing.

- Interazione:
  - L'investigatore pone domande scritte.
  - L'entità nascosta fornisce risposte scritte.
  - L'investigatore deve capire se dall'altra parte c'è un computer o una persona. Se all'altra parte c'è un computer e l'investigatore non riesce a distinguerlo allora il computer si può dire *intelligente*.
- Basta produrre gli output attesi per dire che vi è comprensione? (fig. 1.3)

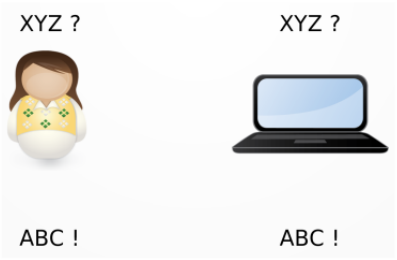

Figure 1.3: Scambio di messaggi.

Esperimento di J. Searle (la stanza cinese):

- Un computer, programmato per rispondere con certi ideogrammi cinesi ad altri ideogrammi cinesi ricevuti in input (fig. 1.4. L'interlocutore umano che parla in cinese non vede il computer che è chiuso in una stanza. Cosa penserà di chi è nella stanza?

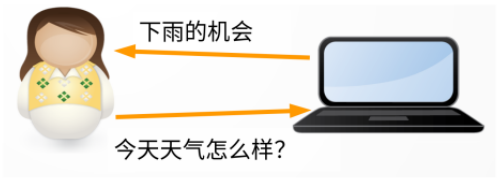

Figure 1.4: Rappresentazione dell'esperimento di Searle.

- Il computer parla cinese? Lo capisce?
- Una persona chiusa in una stanza ha istruzioni per rispondere con certi ideogrammi cinesi in risposta ad altri ideogrammi cinesi (fig. 1.5).

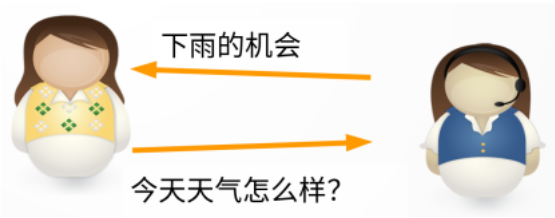

Figure 1.5: Esperimento con una persona.

- Scrivere un programma per un computer non è di per sé una condizione sufficiente per implicare l'intenzionalità.

Note:-

Searle ha scelto il cinese perché voleva considerare una lingua difficile da capire. Per me è skill issue.

AI:

- *AI forte*: è possibile riprodurre l'intelligenza umana? Compresa la consapevolezza di sé, l'essere senziente, etc.
- *AI debole*: esistono modi automatici per risolvere problemi che a un essere umano richiedono intelligenza? Task-oriented, studio del pensiero e del comportamento umano.

1.2.2 Agenti Intelligenti

Agenti triviali (non interessanti):

- Termostato.
- UNIX deamon[3]

Un agente intellingente deve eseguire azioni in modo *flessibile*:

- *Reattivo*.
- *Proattivo*.
- *Sociale*.

Osservazioni 1.2.1

- Se l'ambiente di un software è statico/fisso non è necessario preocuparsi di esso (e. g. un compilatore, un package manager).
- Nel mondo reale le cose cambiano, le informazioni sono incomplete.
- È necessario considerare la possibilità che l'esecuzione di azioni (istruzioni) non abbia successo, è necessario chiedersi se valga la pena eseguire una certa azione.

Definizione 1.2.1: Agente Reattivo

Un agente reattivo è un sistema che mantiene una costante interazione con l'ambiente e risponde ai cambiamenti he occorrono in esso (in tempo perché la risposta sia utile).

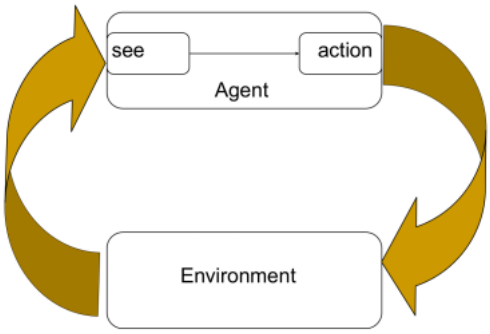

Figure 1.6: Un agente reattivo.

Note:-

Può essere visto come un if then.

Osservazioni 1.2.2

- Reagire a un ambente è facile, però in generale, si vuole che gli agenti "facciano cose per noi".
- *Goal directed behaviour*: comportamento guidato dagli obiettivi.
- *Proattività*: generare e tentare di raggiungere gli obiettivi, non solo guidati dagli eventi, ossia *prendere l'iniziativa*.
- Riconoscere le opportunità.

Definizione 1.2.2: Agente Proattivo

Lo stato dell'agente contiene due tipi di conoscenza:

- L'agente necessita di informazioni su come l'ambiente evolve.
- L'agente necessità di informazioni su come le proprie azioni impattano sull'ambiente.

L'agente necessita di informazioni sull'*obiettivo* (goal) in modo che l'agente possa agire per raggiungerlo. Nel farlo l'agente deve essere in grado di lavorare su *piani*.

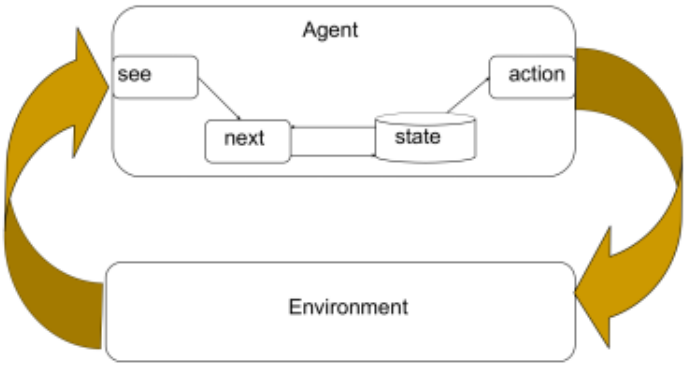

Figure 1.7: Agente proattivo.

[3]Come si permette di dire che il daemon UNIX non è interessante. Probabilmente non ha mai speso il pomeriggio a riaggiustarlo dopo aver rotto un arch install >:(

Reattivo vs. Proattivo:

- Si desidera che gli agenti siano reattivi e che rispondano ai cambiamenti per tempo.
- Si desidera che gli agenti lavorino in modo sistematico verso obiettivi di lungo termini.
- Queste due considerazioni possono essere in conflitto.
- Progettare un agente che bilanci reattività e proattività è ancora un problema aperto.

Osservazioni 1.2.3

- Il mondo reale è spesso un ambiente multiagente, per cui non si possono raggiungere i propri obiettivi senza l'aiuto degli altri.
- Alcuni obiettivi possono essere raggiunti solo con la collaborazione di altri.
- Allo stesso modo i sistemi sono immersi in una rete di computer.

Definizione 1.2.3: Abilità Sociale

Per abilità sociale di un agente intelligente si intende l'abilità di interagire con altri agenti (anche umani) attraverso un qualche tipo di *linguaggio di comunicazione* (*agent-communication language*, *ACL*) e cooperare con essi.

Domanda 1.4

Agente intelligente o generico programma?

Definizione 1.2.4: Is it an Agent or just a Program?

Un agente autonomo è un sistema situato in un ambiente che può percepire e agire su di esso nel tempo con il fine di perseguire una propria agenda e così facendo influire nelle successive percezioni.

Note:-

Secondo questa definizione sia gli esseri umani che i termostati sono agenti autonomi.

1.3 Cenni alla Computazione

L'ingegneria del software aspira a produrre software di qualità (tramite la *modularizzazione*):

- Correttezza.
- Robustezza.
- Estensibilità.
- Riusabilità.

Note:-

Che sono le stesse cose del software *suckless* che è 100% FOOS, ma ovviamente il prof non ne parla.

Meyer individua, nei linguaggi di programmazione, tre forze (fig. 1.8):

- Processo: la CPU fisica, un processo o un thread.
- Azione: operazioni che costituiscono la computazione.
- Oggetto: le strutture dati a cui si applica l'azione.

Figure 1.8: Il triangolo di Meyer.

Decomposizione funzionale (a dispetto del nome è l'approccio del paradigma imperativo):

- PRO:
  - Semplice e intuitivo: si costruisce un sistema con la decomposizione in passi.
  - Orientato agli algoritmi: utile quando si ha un solo top goal.
- CONTRO:
  - Difficile da mantenere[4]: difficile incorporare nuovi goal.
  - Difficilmente scalabile in presenza di dati condivisi e processi concorrenti.

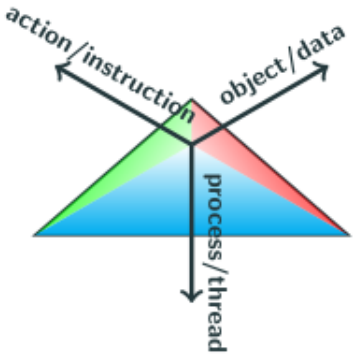

Figure 1.9: Decomposizione funzionale.

Decomposizione orientata agli oggetti:

- PRO:
  - Gli oggetti hanno una vita loro, indipendentemente dal processo che li usa.
  - Operazioni sui dati: fornisce azioni per lavorare su essi.

[4]Skill issue.

  - GLi oggetti sono modelli.

- Contro:
  - Gli oggetti sono passivi: un processo esterno prende la decisione su quale azione invocare su un oggetto.
  - Non c'è differenza tra uso di un oggetto e gestione di un oggetto.
  - Non c'è supporto concettuale alle specifiche di un task.

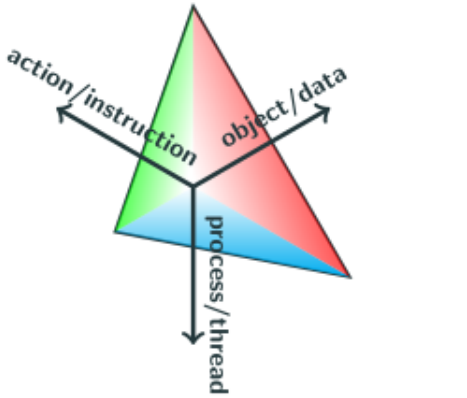

Figure 1.10: Decomposizione orientata agli oggetti.

Modello ad attori e oggetti attivi:

- Gli attori hanno il proprio thread.
- Il modello degli attori non prende in considerazione il problema della coordinazione (sebbene siano state previste estensioni).
- Secondo le forze di Meyer:
  - Supporta la gestione dei dati e degli oggetti.
  - Non supporta la modularizzazione usando gli oggetti stessi.

Processi di Business:

- Crea una rappresentazione esplicita delle attività di un'organizzazione.
- Descrive come un insieme di attività collegate conducano a risultati precisi e misurabili in risposta a un evento esterno.
- Si mette enfasi sulla forza processo (visione attività-centrica).
- Ha gli stessi limiti della decomposizione funzionale.

Gestione dei processi artefatto-centrica:

- Ci si sposta da una visione attività-centrica a una visione dato-centrica.
- Business artifact (BA).

1.3.1 Paradigma Orientato agli Agenti e Architetture per Sistemi ad Agenti

Definizione 1.3.1: Paradigma Orientato agli Agenti

Il paradigma orientato agli agenti si basa su due astrazioni:

- Agente (forza processo).
- Ambiente (forza azione/oggetto).

Agenti vs. Oggetti:

- Gli oggetti non hanno controllo sul proprio comportamento.
- Gli oggetti non hanno un comportamento flessibile.
- Gli oggetti sono single-threaded.

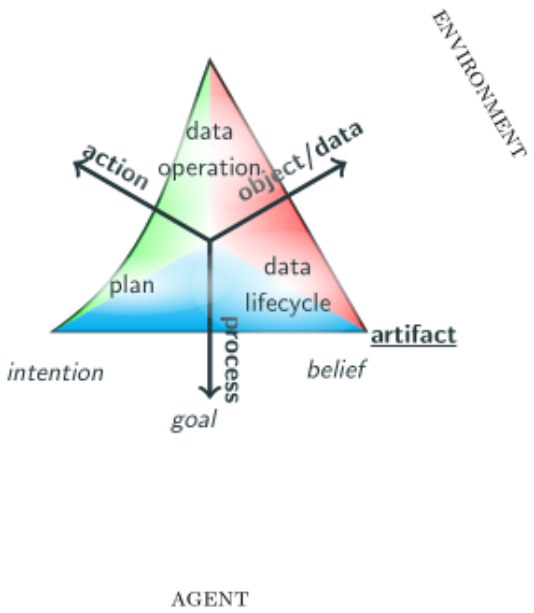

Figure 1.11: Forze nel paradigma Agent-oriented.

Domanda 1.5

Come realizzare agenti intelligenti? Come costruire agenti che abbiano le caratteristiche di autonomia, di reattività, di proattività e di abilità sociali fin qui citate?

- 1956-1985: la maggior parte dei progetti di architetture per agenti si basano sul *ragionamento simbolico* sviluppato per IA. Utilizzo del ragionamento logico per capire cosa fare.
- 1985-presente: *Reactive agents movements*.
- 1990-presente: *architetture ibride* che combinano il meglio delle architetture basate sul ragionamento logico e quelle reattive. (e. g. Jason).

Note:-

Il classico approccio per costruire agenti intelligenti è quello di vederli come casi particolari di sistemi basati sulla conoscenza (paradigma *symbolic AI*).

L'architettura di un agente deliberativo:

- Contiene una esplicita rappresentazione (*modello simbolico*) dell'ambiente.
- Prende decisioni attraverso un *ragionamento simbolico*.

Però ci sono due problemi da affrontare:

- *Il problema della trasduzione*: il problema della traduzione del mondo reale, dell'ambiente, in una descrizione simbolica accurata, in tempo perché possa essere utile.
- *Il problema della rappresentazione/ragionamento*: il problema di come rappresentare simbolicamente le informazioni su entità e processi complessi del mondo reale, e come fare in modo che gli agenti ragionano con queste informazioni in tempo perché i risultati possano essere utili.

Osservazioni 1.3.1

- Entrambi i problemi non sembrano facilmente risolvibili, servono alternative.
- Il problema risiede nella *complessità* degli algoritmi di manipolazione simbolica. La maggior parte degli algoritmi rilevanti sono *altamente intrattabili*.

2
Logica per Agenti

La logica è stata sviluppata nel corso di molti secoli da matematici e filosofi per modellare il "ragionamento corretto" degli esseri umani e ha avuto un ruolo importante nello sviluppo dell'intelligenza artificiale per realizzare agenti e sistemi multiagente.

La logica fornisce strumenti formali per:

- *La rappresentazione della conoscenza*:
  - Un linguaggio formale con una semantica precisa.
  - Rappresentazione dichiarativa della conoscenza.
- *Ragionamento automatico*:
  - Refole di inferenza.

Note:-

Queste proprietà della logica hanno diverse qualità: per esempio possono spiegare in modo preciso i passi di ragionamento di un agente.

Ruoli della logica per gli agenti:

- La logica può essere utilizzata da un agente intelligente per *rappresentare la conoscenza* e per *ragionare*. Dato che la conoscenza è espressa in un linguaggio formale, gli agenti possono usare metodi formali per derivare altra conoscenza.
- La logica può servire per *specificare il comportamento* di un agente intelligente. In questo caso la logica può essere usata per *verificare* che l'agente si comporti come specificato, anche se l'agente non fa uso della logica nel suo funzionamento.

La logica classica:

- Normalmente, quando si parla di logica in ambito AI si intende la *logica classica*, ossia la *logica proposizionale* o la *logica del primordine*.
- Però la necessità di modellare concetti diversi e le esigenze di efficienza hanno portato l'AI all'uso di logiche diverse da quelle classiche e anche alla definizione di nuove logica, per esempio le logiche non monotone.
- Nell'ambito degli agenti e dei sistemi multiagente si preferisce utilizzare la *logica modale*.

2.1 Richiami di Logica Classica

Definizione 2.1.1: Logica Classica

Le formule sono costituite da proposizioni atomiche appartenenti a un insieme P e da connettivi logici secondo la seguente formulazione, con $p \in P, \phi, \psi$ sono formule:

- p.
- $\phi \vee \psi$.
- $\neg\phi$.

Note:-

Quelli presentati nella definizione sono solo alcuni dei connettivi (ci sono anche and, nand, nor, xor, implica, etc.).

2.1.1 Semantica

Definizione 2.1.2: Semantica della Logica Proposizionale

La semantica definisce la verità delle formule rispetto a ogni modello. Nella logica proposizionale, un modello assegna un valore di verità (true o false) a ogni simbolo proposizionale.

Osservazioni 2.1.1

- Se $|P| = n$ ci sono n modelli (tavole di verità).
- Un modello può essere rappresentato come un insieme $M \subseteq P$ che contiene tutte le proposizioni atomiche che sono vere nel modello. Quelle che non appartengono a M sono false.

Definizione 2.1.3: Soddisfacibilità

La semantica definisce una relazione di soddisfacibilità $M \vDash \phi$ di una formula ϕ in un modello M (interpetazione):

- $M \vDash p$ se e solo se $p \in M$.
- $M \vDash \phi \vee \psi$ se e solo se $M \vDash \phi$ o $M \vDash \psi$.
- $M \vDash \neg\phi$ se e solo se $M \nvDash \phi$.

Osservazioni 2.1.2

- Una formula è *soddisfacibile* se è solo se c'è *qualche* modlelo che la soddisfa.
- Una formula è *valida* se e solo se è soddisfatta da *ogni modello* (tautologia).

2.1.2 Sistemi Deduttivi e Logica del Primordine

Definizione 2.1.4: Modus Ponens

$$\frac{\alpha \Rightarrow \beta \quad \alpha}{\beta}$$

Note:-

L'applicazione di una sequenza di regole di inferenza porta a una derivazione $KB \vdash \alpha$. Ovviamente ciò che si deriva da un insieme KB è vero in tutti i modelli di KB.

Definizione 2.1.5: Deduzione

Data una base di conoscenza (insieme di formule) da KB, una formula α segue logicamente da KB:

$$KB \vDash \alpha$$

se e solo se, in ogni modello in cui KB è vera, anche α lo è.

Corollario 2.1.1 Teorema di Deduzione

Date due formule α e β,

$$\alpha \vDash \beta$$

se e solo se la formula

$$\alpha \Rightarrow \beta$$

è valida.

Note:-

La logica classica del primordine estende la logica proposizionale con quantificatori universali ed esistenziali.

2.2 La Logica Modale

2.2.1 Inadeguatezza della Logica Classica

Gli agenti sono descritti come *sistemi intenzionali* attribuendo loro *stati mentali*. Supponiamo di voler formulare, con la logica, la seguente frase: *John crede che Superman voli*. In logica classica questo potrebbe essere espresso come: *Bel(John, vola(Superman))*, dove *Bel* è un predicato.

Questa formulazione non funziona per almeno due ragioni:

- *Ragione sintattica*: le formule della logica classica hanno la seguente struttura *Predicato(Term, ..., Term)*, però il secondo argomento di *Bel* è una formula e non un termine come richiesto.

- *Ragione semantica*: gli operatori intenzionali come *Bel*sono *referentially opaque*, ossia creano contesti chiusi in cui non è possibile sostituire una formula con una equivalente come in logica classica.

2.2.2 Introduzione alla Logica Modale

La semantica della *logica modale* è formulata in termini di *mondi possibili*. Ogni mondo rappresenta una situazione considerata possibile dall'agente. Ciò che è vero in tutti i mondi si può dire sia creduto dall'agente.

- Da un punto di vista filosofico, la proprietà fondamentale della logica modale è che tutto ciò che è vero in tutti i mondi è *necessariamente* vero. Ciò che è vero in qualche mondo è *possibile*.

- La logica modale è stata sviluppata per distinguere tra *verità necessarie* e *verità contingenti*.

Definizione 2.2.1: Logica Modale

La logica modale proposizionale estende la logica classica proposizionale con due operatori modali: $\Box$ (verità necessaria) e $\Diamond$ (verità contingente/possibile). Le formule sono:

- p
- $\varphi \vee \psi$
- $\neg\varphi$
- $\Box\varphi$
- $\Diamond\varphi$

Dove $p \in P$ e φ e ψ sono formule della logica.

Osservazioni 2.2.1

- I due operatori modali sono uno il duale dell'altro: $\Box\varphi \equiv \neg\Diamond\neg\varphi$ (se è necessario che φ sia vera allora, indipendentemente da cosa sia, non è possibile che φ sia falsa) e $\Diamond\varphi \equiv \neg\Box\neg\varphi$ (se è possibile che φ sia vera allora non è vero che è falsa in tutti i mondi, poiché in *almeno* un mondo è vera).
- Volendo si potrebbe minimizzare l'uso della sintassi utilizzando solo uno dei due operatori.

Definizione 2.2.2: Semantica della Logica Proposizionale

- Un *modello* della logica modale è dato come un insieme di mondi possibili.
- Ogni *mondo* è costituito da un insieme di proposizioni che sono considerate vere in quel mondo.
- La *struttura* del modello è descritta da una *relazione binaria di accessibilità* che collega coppie di mondi.

Corollario 2.2.1 Modello

Un modello M è una tripla $\langle W, R, L\rangle$ dove:

- W è un insieme di mondi.
- $R \subseteq WxW$ è una relazione di accessibilità tra mondi.
- $L : W \to 2^P$ dà l'insieme di proposizioni vere in ogni mondo in W.

Esempio 2.2.1 (Modello)

- $W = \{w_1, w_2, w_3, w_4, w_5\}$
- $R = \{\langle w_1, w_2\rangle, \langle w_1, w_4\rangle, \langle w_2, w_2\rangle, \quad \langle w_2, w_3\rangle, \langle w_3, w_2\rangle, \langle w_3, w_4\rangle, \quad \langle w_5, w_2\rangle, \langle w_5, w_4\rangle, \langle w_5, w_5\rangle\}$
- $L = \{\langle w_1, \{p, q, r\}\rangle, \langle w_2, \{p\}\rangle, \quad \langle w_3, \{p, r\}\rangle, \langle w_4, \{r\}\rangle, \langle w_5, \emptyset\rangle\}$

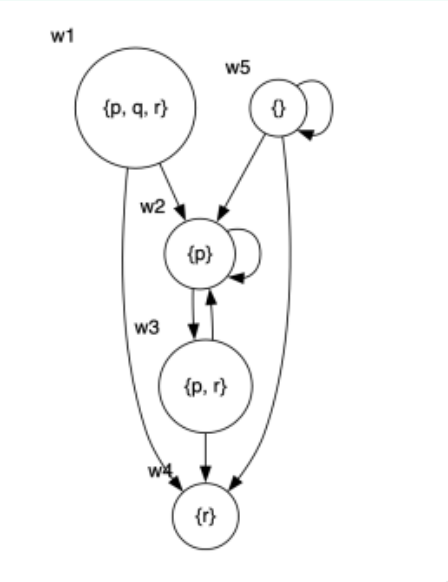

- Da notare che R può collegare un mondo a sé stesso con un loop.

Definizione 2.2.3: Soddisfacibilità

La soddisfacibilità di una formula φ è definita rispetto a un modello M e a un mondo w di questo modello con la notazione $M \models_w \varphi$:

- $M \models_w p$ se e solo se $p \in L(w)$
- $M \models_w \varphi \vee \psi$ se e solo se $M \models_w \varphi$ or $M \models_w \psi$
- $M \models_w \neg\varphi$ se e solo se $M \not\models_w \varphi$
- $M \models_w \Box\varphi$ se e solo se $\forall w' \, (R(w, w') \Rightarrow M \models_{w'} \varphi)$
- $M \models_w \Diamond\varphi$ se e solo se $\exists w' \, (R(w, w') \Rightarrow M \models_{w'} \varphi)$

Corollario 2.2.2 Validità

Una formula φ è valida se è vera in tutte le coppie modello/mondo. La nozione di validità è analoga a quella di tautologia (qualcosa che è sempre vero) nella logica proposizionale classica.

Note:-

I modelli della logica modale sono spesso chiamati *Kripke Structures*. La coppia $\langle W, R \rangle$ è chiamata *Kripke frame*.

Proprietà fondamentali della logica modale:

1. *Assioma K*[1]: $K : \Box(\varphi \Rightarrow \psi) \leftrightarrow (\Box\varphi \Rightarrow \Box\psi)$.
2. *Necessitation*, regola di inferenza: se φ è valida allora $\Box\varphi$ è valida.

Note:-

L'assioma K è proprio delle logiche modali "normali". Esistono altre logiche modali che non l'hanno.

[1] Sempre in onore di Kripke.

Distribuitività:

- La logica modale distribuisce su AND: $\Box(\varphi \wedge \psi) \equiv (\Box\varphi \wedge \Box\psi)$.
- La logica modale non distribuisce su OR: $\Box(\varphi \vee \psi) \not\equiv (\Box\varphi \vee \Box\psi)$.

Domanda 2.1

Ma cosa c'entra questa logica con gli agenti?

- Si dà agli operatori modali un significato diverso da quello standard (necessario o possibile) per modellare una proprietà degli agenti, senza modificare la semantica dei mondi possibili.
- Si attribuisce all'operatore $\Box$ il significato di *credere* (belief), ergo $\Box\varphi$ significa che l'agente crede che φ sia vero.
- Per chiarezza l'operatore $\Box$ è chiamato B (ossia belief, credenza). All'operatore duale non viene attribuito un nome.

Principali logiche modali per agenti:

- *Logica epistemica* (conoscenza e credenza):
  - $K_a\varphi$ l'agente a sa che φ è vero.
  - $B_a\varphi$ l'agente a crede che φ sia vero.
- *Logiche Belief-Desire-Intention*:
  - $B_a\varphi$ l'agente a crede che φ sia vero.
  - $D_a\varphi$ l'agente a desidera φ.
  - $I_a\varphi$ l'agente a ha l'intenzione φ.
- *Logiche deontologiche*:
  - $O\varphi$ è obbligatorio che φ.
  - $P\varphi$ è permesso che φ.
- *Logica temporale* (lineare):
  - $X\varphi$, φ sarà vero al prossimo istante.
  - $G\varphi$, φ sarà sempre vero.
  - $F\varphi$, φ prima o poi diventerà vero.
  - $\psi \cup \varphi$, φ è vero fino a quando φ diventa vero.
- *Logica dinamica* (delle azioni):
  - $[\pi]\varphi$ dopo l'esecuzione del programma π, φ è vero.
  - π è un'azione complessa (programma) ottenuta combinando azioni elementari.

Osservazioni 2.2.2

- Se $\Box$ rappresenta la conoscenza, si vuole che la logica avesse la proprietà che tutto ciò che è conosciuto è vero. Questo può essere espresso aggiungendo l'assioma:

$$\Box\varphi \Rightarrow \varphi$$

- La formula $\Box\varphi \Rightarrow \varphi$ non vale in tutti i modelli.
- Si è può esprimere che le conoscenze dell'agente non devono essere contraddittorie, aggiungendo

l'assioma:

$$\Box\varphi \Rightarrow \neg\Box\neg\varphi$$

Proprietà dei frame:

- *Reflexive* $(\Box\varphi \Rightarrow \varphi)$:
$$\forall w \in W \,.\, (w, w) \in R$$
- *Serial* $(\Box\varphi \Rightarrow \Diamond\varphi)$:
$$\forall w \in W \,.\, \exists w' \in W \,.\, (w, w') \in R$$
- *Transitive* $(\Box\varphi \Rightarrow \Box\Box\varphi)$:
$$\forall w, w', w'' \in W \,.\, ((w, w') \in R \wedge (w', w'') \in R) \Rightarrow (w, w'') \in R$$
- *Euclidean* $(\Diamond\varphi \Rightarrow \Diamond\Diamond\varphi)$:
$$\forall w, w', w'' \in W \,.\, ((w, w') \in R \wedge (w, w'') \in R) \Rightarrow (w', w'') \in R$$

Note:-

A ciascuno di queste proprietà è stato dato un nome, in ordine: T, D, 4 e 5. Combinando queste proprietà si ottengono 11 sistemi modali (sarebbero 16, ma alcuni sono equivalenti).

Ad alcuni sistemi "notevoli" è stato dato un nome:

- KT è T.
- KT4 è S4.
- KD45 è weak-S5.
- KTD45 è S5.

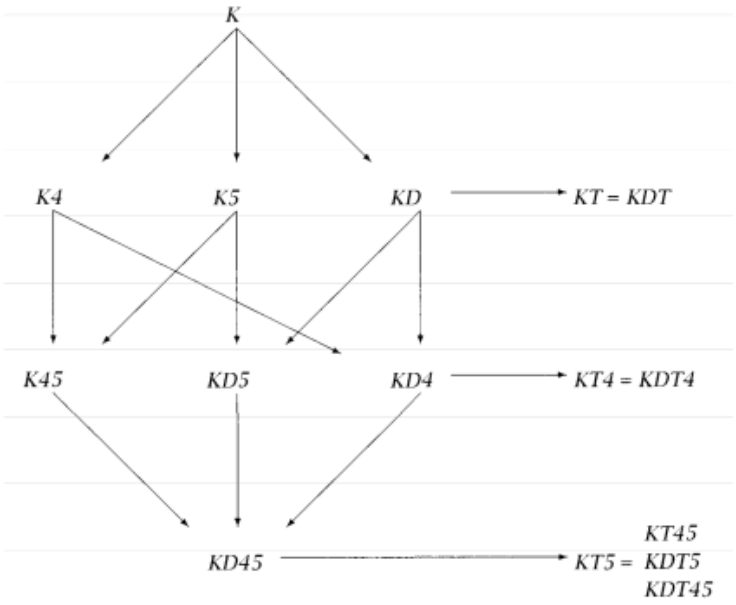

Figure 2.1: Gli 11 sistemi modali.

2.3 Sistemi Modali

2.3.1 Accenni di Logica Epistemica

Definizione 2.3.1: Logica Epistemica

La logica epistemica è la logica della conoscenza e delle credenze. Si introducono i due operatori modali K_a e B_a per rappresentare rispettivamente la conoscenza e le credenze di un agente.

- *Assioma K*: $K_a(\varphi \Rightarrow \psi) \leftrightarrow (K_a\varphi \Rightarrow K_a\psi)$.
- *Necessitation*: se φ è valida, allora $K_a\varphi$.

Il problema dell'omniscienza logica:

- Si assume che ψ sia una conseguenza logica di φ. Allora $\varphi \Rightarrow \psi$ deve essere valida. Secondo la necessitation questa formula deve essere conosciuta dall'agente: $K_a(\varphi \Rightarrow \psi)$.
- Questo significa che l'agente deve conoscere tutte le tautologie (che sono infinite).
- Inoltre se l'agente conosce φ, per l'assioma K, deve conoscere ψ. Questo significa che la conoscenza dell'agente è chiusa rispetto alla conseguenza logica.
- In altre parole se l'agente conosce una cosa e questa cosa ne implica un'altra allora l'agente deve conoscere anche quell'altra cosa.
- In questo corso si ignora completamente il problema.

Figure 2.2: Agente: "Throughout Heaven and Earth, I alone am the omniscient one".

2.3.2 Assiomi per Knowledge e Belief

Si possono realizzare dei sistemi modali aggiungendo nuovi assiomi alla logica modale standard:

- *Assioma D (serialità):* la conoscenza di un agente è non contraddittoria, $K\varphi \Rightarrow \neg K\neg\varphi$, se l'agente conosce φ allora non conosce $\neg\varphi$.
- *Assioma T (riflessività):* ciò che l'agente conosce è vero, $K\varphi \Rightarrow \varphi$, è accettabile per la conoscenza (non vogliamo che l'agente conosca qualcosa che è falso) ma non per le credenze (si accetta che l'agente creda vero qualcosa che è falso).
- *Assioma 4 (transitività):* $K \Rightarrow KK\varphi$.
- *Assioma 5:* $\neg K\varphi \Rightarrow K(\neg K\varphi)$.

Note:-

Gli assiomi di introspezione (4 e 5) implicano che l'agente ha conoscenza perfetta su quello che sa e quello che non sa.

Esempio 2.3.1 (Muddy Children)

- Consideriamo un esempio classico: dopo aver giocato nel fango, due bambini sanno che almeno uno di loro ha del fango sulla fronte (in realtà tutti e due lo hanno). Di solito i bambini sono almeno tre, ma per semplicità consideriamo il caso con due.
- Ogni bambino può vedere la fronte dell'altro, ma non la propria.
- Inizialmente il bambino B dice:

  "Non so se ho la fronte infangata"

- Successivamente il bambino A dice:

  "Io so di avere la fronte infangata"

- Indichiamo con K_A e K_B le conoscenze del bambino A e di B.

Quindi:

1. $K_A(\neg\text{muddy}(A) \Rightarrow K_B(\neg\text{muddy}(A)))$
2. $K_A(K_B(\neg\text{muddy}(A) \Rightarrow \text{muddy}(B)))$
3. $K_A(\neg K_B(\text{muddy}(B)))$
4. $\neg\text{muddy}(A) \Rightarrow K_B\neg\text{muddy}(A)$, da (1) e l'assioma della conoscenza ($K\varphi \Rightarrow \varphi$) (ciò che è conosciuto è vero)
5. $K_B(\neg\text{muddy}(A) \Rightarrow \text{muddy}(B))$, da (2) e l'assioma della conoscenza
6. $K_B\neg\text{muddy}(A) \Rightarrow K_B\text{muddy}(B)$, da (5) e l'assioma K ($K(\varphi \Rightarrow \psi) \Rightarrow (K\varphi \Rightarrow K\psi)$)
7. $\neg\text{muddy}(A) \Rightarrow K_B\text{muddy}(B)$, da (4) e (6) per transitività (se $\alpha \Rightarrow \beta$ e $\beta \Rightarrow \gamma$, allora $\alpha \Rightarrow \gamma$)
8. $\neg K_B\text{muddy}(B) \Rightarrow \text{muddy}(A)$, contrapposto di (7) ($\alpha \Rightarrow \beta \equiv \neg\beta \Rightarrow \neg\alpha$)
9. $K_A(\neg K_B\text{muddy}(B) \Rightarrow \text{muddy}(A))$, da (8) per necessitation (derivazione: (1) e (2) significano che A conosce le formule (4) e (5). Dalle formule (4) e (5) si deriva la formula (8), quindi (4) e (5) implicano (8) per il teorema di deduzione. La regola dell'onniscienza logica implica che A conosce la formula (8))
10. $K_A\neg K_B\text{muddy}(B) \Rightarrow K_A\text{muddy}(A)$, da (9) e l'assioma K

2.3.3 Ragionare sul Tempo

La logica temporale è la logica modale del tempo. Ci sono molte varianti della logica temporale. In questo corso si tratterà solo il caso in cui il tempo:

- Ha un instante iniziale.
- È infinito nel futuro.

Definizione 2.3.2: Linear Temporal Logic (LTL)

La struttura del tempo è un insieme totalmente ordinato di istanti di tempo. Un modello M è una struttura lineare, spesso chiamata *Kripke structure*, definita come:

$$M = \langle S, x, L \rangle$$

Dove:

- S è un insieme di stati.
- $x : \mathbb{N} \to S$ è una sequenza infinita di stati, con $\mathbb{N}$ che rappresenta l'insieme dei numeri naturali.
- $L : S \to 2^P$ assegna a ogni stato l'insieme delle proposizioni vere in quello stato.

Corollario 2.3.1 Formule

Le formule della Propositional Linear Temporal Logic (PLTL) sono definite come segue:

- p, con $p \in P$
- $\alpha \vee \beta$
- $\neg\alpha$
- $X\alpha$
- $\alpha U \beta$

Dove $\alpha, \beta \in$ PLTL.

Semantica informale degli operatori modali:

- $X\alpha$ ("nexttime α") significa che α è vero nel prossimo istante di tempo.
- $\alpha U \beta$ ("α until β") è vero al tempo t se e solo se β è vero in un futuro istante t_0 e α è vero in tutti gli istanti fra t e t_0.

Operatori modali derivati:

- $F\alpha \equiv \text{true} U \alpha$ ("prima o poi α").
- $G\alpha \equiv \neg F \neg \alpha$ ("sempre α").

In Computing Tree Logic (CTL*) è possibile formulare due tipi di formule:

- **Path formulas:** riguardano i cammini infiniti della struttura temporale ad albero e sono simili alle formule della Logica Temporale Lineare (LTL).
- **State formulas:** riguardano tutti i cammini infiniti uscenti da uno stato.

Domanda 2.2

Quali sono gli usi delle logiche temporali:

- Sono usate per verificare la correttezza di sistemi concorrenti (e. g. multiagente) con la tecnica del *model checking*.
- Dato che il model checking affronta problemi ad alta complessità si utilizza una logica CTL (che restringe la sintassi della CTL*).

Definizione 2.3.3: Model Checking

Il model checking è un metodo per la verifica di proprietà di agenti e di sistemi multiagente (o, in generale, sistemi concorrenti).

Note:-

Le proprietà da verificare sono basate su logiche temporali e sulla relazione tra i modelli delle logiche temporali e degli automi a stati finiti che ne descrivono le computazioni.

2.3.4 Ragionare sulle Azioni

Il ragionamento sulle azioni si basa sulla logica classica:

- *Situazioni*: stato del mondo a qualche istante nel tempo.
- *Fluenti*: proposizioni il cui valore varia da una situazione all'altra.
- *Azioni*: causano un cambiamento nello stato del mondo.

Definizione 2.3.4: Azione

Ogni azione è descritta da due assiomi:

- Un'assioma di possibilità: che dice quando è possibile eseguire l'azione.
- Un'assioma di effetto: cosa accade quando un'azione possibile è eseguita.

Definizione 2.3.5: Frame Problem

Un'azione influenza solo un numero limitato di fluenti. Bisogna trovare un modo per descrivere il fatto che tutto il resto non cambi.

3
Agenti Razionali e Architetture

3.1 Credenze, Desideri e Intenzioni

Definizione 3.1.1: Sistema Intenzionale

Un sistema intenzionale è un sistema il cui comportamento può essere previsto dal metodo di attribuzione di credenze, di desideri e di acume razionale.

Note:-

Per McCarthy, in alcuni casi si possono attribuire posizioni intenzionali a sistemi informatici.

Osservazioni 3.1.1

- Più si sa di un sistema meno si fa affidamento a spiegazioni animistiche.
- Con sistemi complessi una spiegazione meccanica potrebbe non essere praticabile.

Definizione 3.1.2: Intenzioni e Astrazioni

Più i sistemi di calcolo diventano complessi più si ha bisogno di astrazioni e metafore per spiegare il loro funzionamento. Le posizioni intenzionali sono una tale astrazione.

Note:-

Le nozioni intenzionali sono quindi astrazioni che forniscono un modo semplice e familiare per descrivere, spiegare e prevedere il comportamento di sistemi complessi.

I più importanti sviluppi sono basati su astrazioni:

- Procedure e funzioni.
- Tipi di dati astratti (bloat).
- Oggetti.
- Agenti intelligenti e sistemi intenzionali.

3.1.1 Ragionamento su Azioni

Definizione 3.1.3: Pratical Reasoning

Il pratical reasoning è il ragionamento sulle azioni, sul processo di capire cosa fare.

Note:-

Si distingue da theoretical reasoning che riguarda le credenze.

Il pratical reasoning consiste in:

- *Deliberazione*: decidere quale stato di cose vogliamo raggiungere.
- *Pianificazione* (menas-ends reasoning/planning): decidere come raggiungere questi stati di cose.

Note:-

Dopo aver ottenuto un piano un agente tenterà di eseguirlo.

Osservazioni 3.1.2

- Il calcolo è una risorsa preziosa per gli agenti, un agente deve controllare il suo ragionamento.
- Gli agenti non possono deliberare a tempo indeterminato, a un certo punto devono smettere di deliberare e, dopo aver scelto uno stato di cose, impegnarsi per raggiungerlo.

Corollario 3.1.1 Intenzioni

Ci riferiamo allo stato di cose che un agente ha scelto e al quale si impegna come le sue intenzioni.

Note:-

Il ruolo delle intenzioni è quello di *favorire la proattività*, ossia portare all'azione.

Conseguenze:

- Persistenza delle azioni: se si adotta un'intenzione allora si deve insistere su essa e tentare di realizzarla. Se la motivazione cessa di esistere è razionale abbandore l'intenzione.
- Le intenzioni vincolano il futuro pratical reasoning.

Intenzioni nel pratical reasoning:

1. Ci si aspetta che gli agenti trovino i modi per realizzare le loro intenzioni.
2. Le intenzioni forniscono un *filtro* per l'adozione di altre intenzioni, che non devono entrare in conflitto.
3. Gli agenti monitorano il successo delle loro intenzioni e sono inclini a *riprovare* se i loro tentativi falliscono.
4. Gli agenti credono che le loro intenzioni siano possibili[1].
5. Gli agenti non credono che non realizzeranno le loro intenzioni[2].
6. Nelle giuste circostanze gli agenti credono che realizzeranno le loro intenzioni.
7. Gli agenti non devono necessariamente avere intenzioni su tutti gli effetti collaterali delle loro intenzioni.

[1] Gli agenti sono come Naruto che vuole diventare Hokage.
[2] Gli agenti sono come Naruto che vuole diventare Hokage pt. 2.

Osservazioni 3.1.3

- Il problema di avere l'intenzione di realizzare qualcosa credendo che non sia possibile è noto come *intention-belief inconsistency* e non è razionale. (punto 5)
- Il problema di avere l'intenzione di realizzare qualcosa senza credere che la realizzeranno è noto come *intention-belief incompleteness* ed è una proprietà accettabile per gli agenti razionali. (punto 6)
- Il problema al punto 7 è noto come *package deal*.

3.1.2 Modellazione Logica di Agenti BDI

- La logica riguarda principalmente il *rational balance* relativo a beliefs, goals, plans, intentions, commitments e azioni di agenti autonomi.
- L'obiettivo principale è di esplorare le reazioni che le intenzioni hanno nel mantenere questo bilanciamento.
- Questo deve essere analizzato con *beliefs*, *desires* e *intentions* (BDI).

La logica di Cohen e Levesque ha 4 operatori modali principali:

- $(BEL\ i\ \phi)$: l'agente i crede ϕ.
- $(GOAL\ i\ \phi)$: l'agente i ha il goal (desire) ϕ.
- $(HAPPENS\ \alpha)$: l'azione α occorre al passo successivo.
- $(DONE\ \alpha)$ l'azione α è appena occorsa.

Note:-

Un'azione α può essere un evento primitivo oppure complesso. L'intenzione non è un operatore primitivo, ma può essere derivato.

Successivamente viene proposta un'altra logica, da Rao e Georgeff (BDI):

- Ci sono tre modalità: BEL, $GOAL$ e $INTEND$.
- I mondi sono strutture temporali branching time.

È possibile descrivere commitments diversi:

- Agente *blindy committed* (fanatical): mantiene le sue intenzioni finché non arriva a credere di averle soddisfatte.
$$INTEND(AF\ \phi) \Rightarrow A(INTEND(AF\ \phi) \cup BEL(\phi))$$
- Agente *Single-minded committed*: mantiene le sue intenzioni finché crede che queste possano essere realizzabili.
$$INTEND(AF\ \phi) \Rightarrow A(INTEND(AF\ \phi) \cup (BEL(\phi) \vee \neg BEL(EF\ \phi)))$$
- Agente *open-minded*: mantiene le sue intenzioni finché queste intenzioni sono ancora i suoi goals.
$$INTEND(AF\ \phi) \Rightarrow A(INTEND(AF\ \phi) \cup (BEL(\phi) \vee \neg GOAL(EF\ \phi)))$$

3.1.3 Un'Architettura per agenti BDI

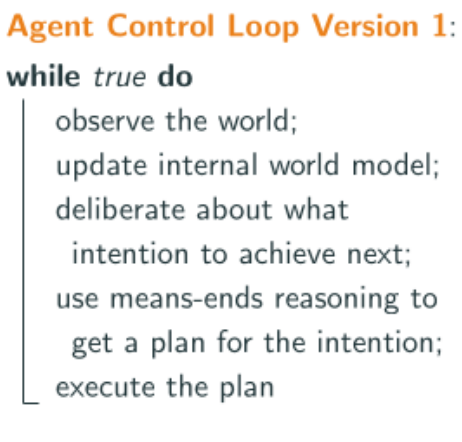

Figure 3.1: Una prima versione di un agente che utilizza il pratical reasoning.

Nella prima versione:

- I processi di deliberation e means-end reasoning non sono immediati, hanno un costo nel tempo.
- Supponiamo che l'agente inizi a deliberare all'istante t_0, inizi il means-end reasoning all'istante t_1 e che cominci l'esecuzione del piano all'istante t_2:
  - Il tempo per deliberare è $t_d = t_1 - t_0$.
  - Il tempo per il means-end reasoning è $t_{me} = t_2 - t_1$.
  - Supponiamo inoltre che la deliberazione sia ottimale, cioè se si seleziona un'intenzione da raggiungere essa sia la migliore per l'agente.
  - Al tempo t_1 l'agente ha selezionato l'intenzione da raggiungere che sarebbe stata ottimale se fosse stata raggiunta all'istante t_0.
  - A meno che t_d sia molto piccolo c'è il rischio che l'intenzione non sia più ottimale (calculative rationality).

L'agente avrà un comportamento complessivo ottimale nelle seguenti circostanze:

- Quando il tempo impiegato per i processi di deliberazione di means-end è estremamente piccolo.
- Quando il mondo è *statico* mentre l'agente effettua o suoi processi.
- Quando un'intenzione ottimale se raggiunta al tempo t_0 (il momento in cui si osserva il mondo) è garantita rimanere ottimale fino al tempo t_2 (il tempo in cui l'agente ha determinato le azioni per raggiungere le intenzioni).

Nella seconda versione:

- B: credenze.
- I: intenzioni.
- $brf()$: revisione delle credenze.
- $deliberate()$: deliberazione delle intenzioni.
- $plan()$: pianificazione.

Agent Control Loop Version 2:

/* initial beliefs */ $B := B_0$;
while *true* **do**
  get next percept ρ;
  $B := brf(B, \rho)$;
  $I := deliberate(B)$;
  $\pi := plan(B, I)$;
  $execute(\pi)$

Figure 3.2: Seconda versione di un agente che utilizza il pratical reasoning.

- La pianificazione è la progettazione di una sequenza di azioni che consentirà di raggiungere l'obiettivo desiderato.
- Dati:
  - Una rappresentazione dell'obiettivo/intenzione da raggiungere.
  - Una rappresentazione delle azioni che può eseguire.
  - Una rappresentazione dell'ambiente.
- Si tratta di automatica programming.

Domanda 3.1

Come un agente delibera?

- *Option generation*: inizia cercando di capire quali sono le opzioni a sua disposizione sulla base delle proprie informazioni e credenze.
- *Filtering:* sceglie tra le opzioni possibili e si impegna verso di esse.

Note:-

Le opzioni scelte sono le intenzioni.

Agent Control Loop Version 3:

$B := B_0$;
$I := I_0$;
while *true* **do**
  get next percept ρ;
  $B := brf(B, \rho)$;
  $D := options(B, I)$;
  $I := filter(B, D, I)$;
  $\pi := plan(B, I)$;
  $execute(\pi)$

Figure 3.3: Terza versione di un agente che utilizza il pratical reasoning.

Nella terza versione:

- $option()$: l'agente genera un insieme di possibili alternative. Rappresenta la generazione di opzioni tramite una funzione.
- $filter()$: l'agente sceglie tra le alternative che competono e si impegna a raggiungerle.
- Quando un'opzione è restituita da filter diciamo che l'agente ha fatto un *commitment* verso tale opzione.
- Il commitment implica persistenza temporale, per cui un'intenzione adottata non dovrebbe essere immediatamente abbandonata.

Definizione 3.1.4: Commitment Strategies

Il meccanismo che un agente usa per determinare quando e come un'intenzione possa essere abbandonata.

Note:-

I tipi di strategie sono gli stessi dei tipi di agente (blind, single-minded, open-minded).

Agent Control Loop Version 4:

```
B := B0;
I := I0;
while true do
    get next percept ρ;
    B := brf(B, ρ);
    D := options(B, I);
    I := filter(B, D, I);
    π := plan(B, I);
    while not empty(π) do
        α := hd(π);
        execute(α);
        π := tail(π);
        get next percept ρ;
        B := brf(B, ρ);
        if not sound(π, I, B) then
            π := plan(B, I)
```

Figure 3.4: Quarta versione di un agente che utilizza il pratical reasoning.

Nella quarta versione:

- Si ripianifica se qualcosa va storto.
- È ancora presente overcommitment rispetto alle intenzioni: non si ferma a valutare se le sue intenzioni siano più o meno adeguate (blind).

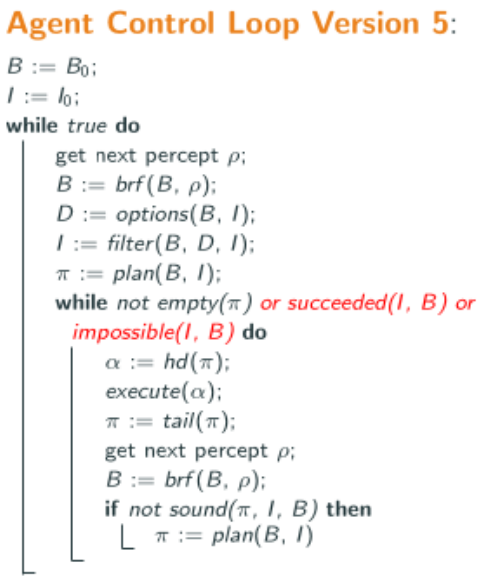

Figure 3.5: Quinta versione di un agente che utilizza il pratical reasoning.

Nella quinta versione:

- Ci si ferma per determinare se le intenzioni hanno avuto successo o se sono diventate impossibili da soddisfare (single-minded).

- L'agente può riconsiderare le sue intenzioni ogni volta che il controllo è sul ciclo esterno, ossia quando:

  - Ha completamente eseguito un piano per raggiungere le sue intenzioni correnti.

  - Ritiene di aver raggiunto le sue attuali intenzioni.

  - Crede che le sue attuali intenzioni non siano più possibili.

- Questo limita il modo in cui consente a un agente di riconsiderare le sue intenzioni.

Agent Control Loop Version 6:

```
B := B0;
I := I0;
while true do
    get next percept ρ;
    B := brf(B, ρ);
    D := options(B, I);
    I := filter(B, D, I);
    π := plan(B, I);
    while not empty(π) or succeeded(I, B) or
      impossible(I, B) do
        α := hd(π);
        execute(α);
        π := tail(π);
        get next percept ρ;
        B := brf(B, ρ);
        D := options(B, I);
        I := filter(B, D, I);
        if not sound(π, I, B) then
            π := plan(B, I)
```

Figure 3.6: Sesta versione di un agente che utilizza il pratical reasoning.

Nella sesta versione:

- Riconsidera le intenzioni dopo l'esecuzione di ogni azione (open-minded).
- Tuttavia la riconsiderazione delle intenzioni costa:
  - Un agente che non si ferma abbastanza spesso continuerà a tentare di raggiungere le sue intenzioni anche dopo che sarà chiaroo che non possono essere raggiunte.
  - Un agente che riconsidera costantemente dedica poco tempo a raggiungere le sue intenzioni.

Figure 3.7: L'agente che riconsidera costantemente be like.

3.1.4 Riconsiderazione delle Intenzioni

Agent Control Loop Version 7:

```
B := B0;
I := I0;
while true do
    get next percept ρ;
    B := brf(B, ρ);
    D := options(B, I);
    I := filter(B, D, I);
    π := plan(B, I);
    while not empty(π) or succeeded(I, B) or
      impossible(I, B) do
        α := hd(π);
        execute(α);
        π := tail(π);
        get next percept ρ;
        B := brf(B, ρ);
        if reconsider(I, B) then
            D := options(B, I);
            I := filter(B, D, I)
        if not sound(π, I, B) then
            π := plan(B, I)
```

Figure 3.8: Settima versione di un agente che utilizza il pratical reasoning.

Nella settima versione:

- Incorpora una componente di controllo esplicita *meta-livello* che decide se eseguire o meno la riconsiderazione.

Situation number	Chose to deliberate?	Changed intentions?	Would have changed intentions?	*reconsider*(...) optimal?
1	No	—	No	Yes
2	No	—	Yes	No
3	Yes	No	—	No
4	Yes	Yes	—	Yes

Figure 3.9: Componente meta-livello.

Note:-

Il problema è che la reconsider() è una funzione oracolo, per cui va implementata mediante euristiche e studi specifici sul dominio. Il costo di questa funzione dovrebbe essere molto inferiore al costo del processo deliberativo stesso.

Kinny e Georgeff hanno investigato ciò in maniera sperimentale:

- Due tipi di agenti:
  - *Bold agents*: non si fermano mai a riconsiderare le intenzioni.
  - *Cautious agents*: riconsiderano le intenzioni dopo ogni azione.

- Considerazioni:
  - Se l'ambiente non cambia rapidamente gli agenti bold funzionano meglio.
  - Se l'ambiente cambia costantemente gli agenti cautious funzionano meglio.

3.2 Linguaggi e Architetture per Agenti

3.2.1 Procedural Reasoning System

Definizione 3.2.1: PRS

Il procedural reasoning system è stata una delle prime architetture per agenti che abbia fatto uso del paradigma BDI. È stata usata in applicazioni multi-agenti.

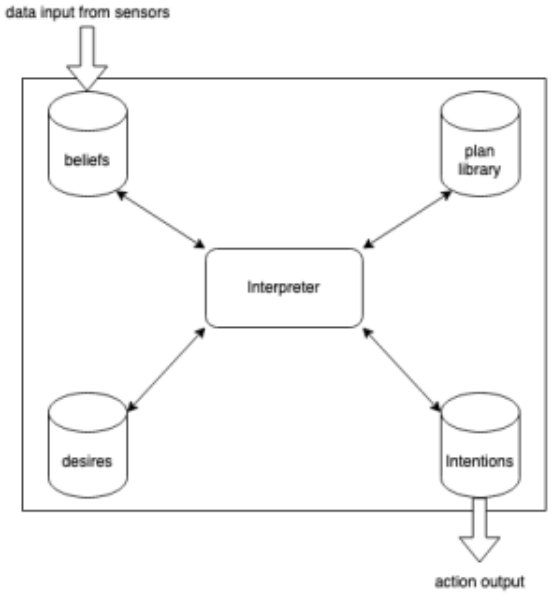

Figure 3.10: Procedural Reasoning System.

Osservazioni 3.2.1

- Gli input del sistema sono *eventi*, ricevuti attraverso una *coda di eventi*.
- Gli eventi possono essere:
  - *Esterni*: percepiti dall'ambiente.
  - *Interni*: come aggiunta o cancellazione di belief o goal.
- Gli output sono azioni che sono eseguite dall'interprete.
- I belief sono rappresentati come fatti del Prolog (atomi della logica del primordine).
- In PRS gli agenti non pianificano, ma fanno riferimento a una libreria di piani predefinita dal programmatore.

I componenti di un piano sono:

- *Nome*.
- *Condizioni di invocazione*.
- *Precondizioni*: le condizioni che devono valere prima di avviare l'esecuzione del piano.
- *Body*: una sequenza di espressioni:
  - Azioni atomiche.
  - Sottogoals.

Note:-

Per raggiungere un dato goal, l'agente formula l'intenzione di raggiungere l'obiettivo, cioè sceglie un piano applicabile. Questo piano diventa un'intenzione, ed è aggiunto alla intention structure.

I piani in PRS:

- I goal in PRS possono essere complessi e contenere a loro volta dei goal.
- I piani possono contenere disgiunzioni di goal, loops, etc.
- Un agente ha un insieme di piani, alcuni belief iniziali riguardo il mondo e un goal iniziale.
- I belief sono rappresentati Prolog-like.

Ragionamento:

- Per raggiungere un dato goal, l'agente formula l'intenzione di raggiungerlo (sceglie un piano applicabile). Il piano diventa un'intenzione ed è aggiunto alla intention structure.
- A ogni passo del loop principale, l'interprete sceglie un piano (parzialmente eseguito) nella intention structure e ne esegue un passo.
- Se ci sono molte opzioni disponibili l'interprete può scegliere quella con la massima utilità o entrare in un ragionamento di meta-livello.

Control loop:

1. Aggiorna belief e goal secondo gli eventi della *event queue*.
2. I cambiamenti dei goal e dei belief fanno scattare i diversi piani.
3. Uno o più piani applicabili sono scelti e messi nella intention structure.
4. Si sceglie una intenzione (task) dalla intention structure.
5. Si esegue un passo di quel task:
   - Esecuzione di un'*azione primitiva*.
   - Scelta di un nuovo subgoal.

Stack delle intenzioni:

- Quando un agente inizia la sua esecuzione, il goal iniziale è inserito nell'intention stack.
- Lo stack contiene tutti i goal in attesa di essere soddisfatti.
- L'agente cerca tra i suoi piani per vedere quali hanno un goal sulla cima dello stack delle intenzioni come la loro post-condizione.
- Tra questi piani alcuni avranno le loro precondizioni soddisfatte dall'insieme di belief correnti.
- L'insieme dei piani che permettono di raggiungere il goal e hanno le precondizioni soddisfatte diventano l'insieme delle possibili opzioni dell'agente.

Osservazioni 3.2.2

- Il processo di selezione tra i diversi piani è la *deliberazione*.
- La deliberazione è ottenuta mediante l'utilizzo di un piano metà meta-livello.
- Effettuata la scelta la sua esecuzione può portare ulteriori goal nello stack.
- Le azioni atomiche potranno essere eseguite direttamente dall'agente.
- Se un piano fallisce, l'agente può selezionare un nuovo piano tra quelli candidati.
- L'esecuzione dei task può essere *interleaved* (supporta il multithread).
- Le intenzioni (task) sono solitamente implementate con uno stack di frames.

Definizione 3.2.2: AgentSpeak(L)

Il linguaggio AgentSpeak(L) è stato proposto come linguaggio di programmazione per agenti (BDI) e consente di essere scritto e interpretato in modo simile a quello dei programmi logici basati su clausole di Horn (Prolog).

Note:-

Si propone di colmare il gap tra specifica teorica e implementazione di un agente BDI. Ha dato origine a JASON.

3.2.2 Agent-Oriented Programming

L'articolo Agent-Oriented programming di Shoham propone un nuovo paradigma di programmazione che promuove una visione sociale della computazione in cui più agenti interagiscono l'uno con l'altro. L'articolo presenta:

- Un linguaggio formale per descrivere stati mentali.
- Un linguaggio di programmazione per definire agenti.

Caratteristiche:

- Ci sono due categorie mentali principali: *belief* e *obligation*. Un'ulteriore categoria, che non è un costrutto mentale, è *capability*.
- *Decision* è una obligation a se stessi.
- Le formule fanno esplicitamente riferimento al tempo. Viene adottato un semplice linguaggio basato sugli istanti di tempo.
- Le azioni non sono distinte dai fatti: la presenza di un'azione è rappresentata dal fatto corrispondente.

Note:-

Il linguaggio di Shoham, Agent0, non ha avuto molta rilevanza, contrariamente al nome Agent-Oriented Programming.

3.2.3 Agenti Reattivi

Note:-

Un linguaggio per agenti reattivi è CLIPS, visto in "Intelligenza Artificiale e Laboratorio".

Tesi di Brooks:

- Un comportamento intelligente può essere generato *senza rappresentazione esplicita* del tipo di ciò che è proposto dall'IA simbolica.
- Un comportamento intelligente può essere generato *senza ragionamento esplicito* del tipo di ciò che è proposto dall'IA simbolica.
- L'intelligenza è una proprietà *emergente* di certi sistemi complessi.

Due idee chiave:

- *Collocazione e personificazione*: l'intelligenza reale è situata nel mondo, non in sistemi senza sostanza come i "theorem provers" o i "sistemi esperti"[3].
- *Intelligenza e apparenza*: il comportamento intelligente è generato come un risultato di un'interazione con l'ambiente.

Definizione 3.2.3: Subsumption Architecture

Una Subsumption Architecture è una gerarchia di task che eseguono behaviours.

Corollario 3.2.1 Behaviour

Una behaviour è una struttura a regole molto semplici.

Subsumption Architecture:

- Ogni behaviours compete con altri per esercitare il controllo sugli agenti.
- Gli strati più bassi rappresentano tipi di behaviours più primitivi e hanno precedenza su strati più in alto nella gerarchia.
- I sistemi risultanti sono estremamente semplici in termini della quantità di computazione che fanno.
- Alcuni robot eseguono task che sarebbero sconvolgenti se eseguiti da sistemi simbolici di AI.

Selezione delle azioni:

- La scelta di un'azione è realizzata mediante insiemi di behaviours (coppie (c, a)):
  - c: insieme di *condizioni*.
  - a: un'azione.
- Un behaviour scatta quando la funzione see restituisce una percezione p tale che $p \in c$.
- Associato a un insieme di behaviour rules c'è una *relazione di inibition*.
- Leggiamo $b_1 < b_2$ come "b_1 inibisce b_2", cioé b_1 è più basso nella gerarchia di b_2, quindi ha priorità.

Definizione 3.2.4: Steels Mars Explorer

Steels propose un sistema di esplorazione per Marte usando la Subsumption Architecture. La soluzione fa uso di due meccanismi:

- Un campo gradiente per trovare la direzione verso la base.
- "Briciole radioattive" per permettere la comunicazione tra agenti.

[3] AKA touch some grass.

Regole non-cooperative:

1. Evitare gli ostacoli.
2. I campioni portati dagli agenti sono depositati alla base.
3. Gli agenti che portano i campioni ritornano alla base.
4. Gli agenti raccolgono i campioni che trovano.
5. Un agente che non sa cosa fare esplora a caso.

Osservazioni 3.2.3

- Si vuole favorire la collaborazione.
- Un agente crea un sentiero di briciole radioattive ogni volta che trova un campione di roccia.
- Il sentiero sarà creato quando un agente riporta le rocce alla base.
- Mentre un agente segue un sentiero verso la sorgente di rocce, raccoglie le briciole rendendo il sentiero più sottile.
- Dopo che un po' di agenti avranno seguito il sentiero senza trovare campioni il sentiero sarà scomparso.

Viene rimossa la regola tre e aggiunte:

6. Se un agente sta portando dei campioni e non è nella base, lascia cadere 2 briciole e va su verso il gradiente.
7. Se un agente percepisce delle briciole ne prende una e va giu verso il gradiente.

Note:-

L'ordine dei behaviours è 1, 2, 6, 4, 7, 5.

Limiti degli agenti reattivi:

- Agenti senza modello devono avere sufficienti informazioni locali.
- Se le decisioni sono locali gli agenti hanno una visione a breve termine.
- Difficili da realizzare.
- È difficile ingegnerizzare agenti specifici.
- È difficile definire agenti con un gran numero di behaviours.

3.2.4 Architetture Ibride

- Molti ricercatori hanno sostenuto che né un approccio completamente deliberativo né un approccio completamente reattivo sono adatti a costruire agenti.
- Ci sono stati suggerimenti di utilizzo di sistemi ibridi.
- Un approccio è quello di costruire un agente con due o più sottosistemi:
  - Uno *deliberativo* contenente un modello simbolico del mondo, che sviluppa piani e prende decisioni nel modo proposto dall'IA simbolica.
  - Uno *reattivo* capace di reagire a eventi senza ragionamenti complessi.

Modelli ibridi:

- Solitamente viene data precedenza ai componenti reattivi.
- Questo tipo di struttura porta a un'architettura a strati.
- I sottosistemi di controllo di un agente sono organizzati in una gerarchia, con livelli più alti che trattano l'informazione a crescenti livelli di astrazione.
- Un problema è il tipo di schema di controllo in cui inserire i sottosistemi.
- Sono stati proposti:
  - *Horizontal layering:* tutti gli strati sono direttamente connessi all'input e all'output.
  - *Vertical layering:* input dei sensori e output delle azioni sono gestiti al massimo da uno strato ciascuno.

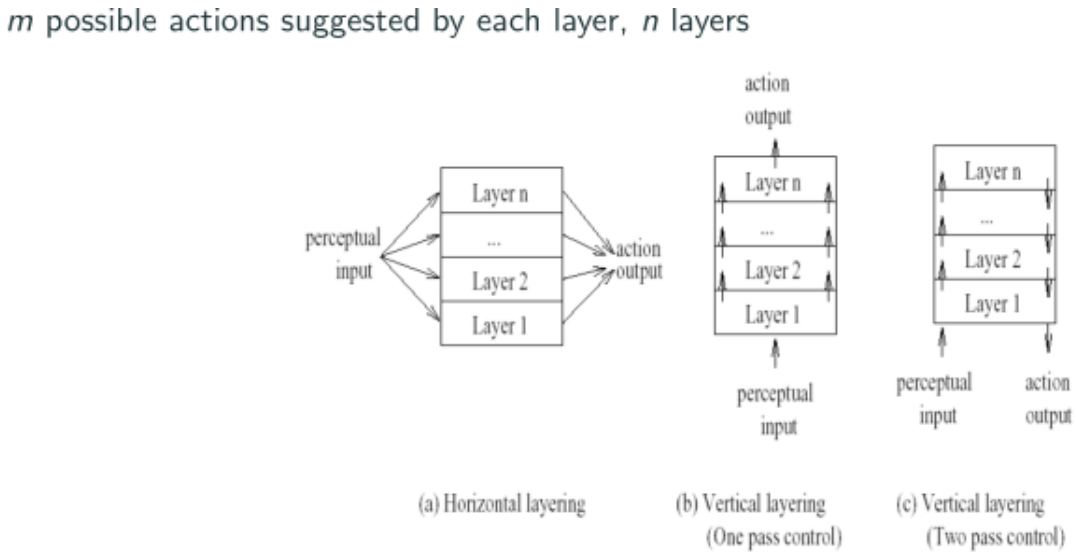

Figure 3.11: Schema delle architetture ibride.

Note:-

Esempi di architetture ibride sono TOURINGMACHINES e Stanley.

4

Sistemi Multiagente

5 Jade e Jason

5.1 Jade

5.2 Jason